

Министерство науки и высшего образования Российской Федерации
Российский химико-технологический университет имени Д.И.
Менделеева

Факультет цифровых технологий и химического инжиниринга
Кафедра информационных компьютерных технологий

ОТЧЕТ
ПО ЛАБОРАТОРНОМУ ПРАКТИКУМУ
«Методы искусственного интеллекта»

Вариант №1

ВЫПОЛНИЛ: студент группы КС-46 Золотухин А.А.
ПРОВЕРИЛ: ассистент Макляев И.В.

Москва

2026

СОДЕРЖАНИЕ

1. Лабораторная работа 1. Решение задачи регрессии	3
1.1. Цель работы. Задача. Вариант задания	3
1.2. Теоретическая часть	3
Архитектуры моделей	3
Алгоритм обучения	3
Метрики качества	3
1.3. Практическая часть	3
1.3.1. Описание данных	3
1.3.2. Предварительный анализ данных (EDA)	4
1.3.3. Обучение моделей и результаты	5
1.4. Выводы по работе	6
2. Лабораторная работа 2. Распознавание символов	6
2.1. Описание задачи	6
2.2. Теоретическая часть	6
2.3. Практическая часть	7
2.3.1. Исследование структуры данных	7
2.3.2. Визуальный анализ (EDA)	7
2.3.3. Влияние количества эпох на точность	7
2.3.4. Результаты и сравнение	8
2.3.6. Тестирование на пользовательских данных	9
2.4. Выводы по работе	10

1. Лабораторная работа 1. Решение задачи регрессии

1.1. Цель работы. Задача. Вариант задания

Цель работы: приобретение навыков анализа данных, проектирования и обучения искусственных нейронных сетей для решения задач аппроксимации и регрессии с использованием фреймворка Keras.

Задача: На основе набора данных «Diamonds» построить модель прогнозирования рыночной стоимости бриллианта в зависимости от его характеристик.

Вариант задания: Вариант 1 (Задание на регрессию).

1.2. Теоретическая часть

Искусственные нейронные сети – это математический аппарат, основанный на аналогиях с функционированием центральной нервной системы и предназначенный для решения широкого круга задач, таких, как распознавание образов, классификация, кластеризация и аппроксимация данных, прогнозирование временных рядов, адаптивное управление и многих других.

Архитектура нейронной сети – совокупность, объединяющая принципы организации и функционирования нейронной сети и отдельных искусственных нейронов, алгоритмы и расчетные соотношения для ее обучения.

Структура нейронной сети - количество слоев, нейронов в каждом слое, а также количество внешних входных и выходных переменных.

Обучение нейронной сети представляет собой процедуру точного или итерационного расчета всех ее весовых коэффициентов, соединяющих внешние входы с нейронами и нейроны между собой.

Под **эпохой обучения** понимается цикл однократного предъявления (как правило, в случайном порядке) всех примеров обучающей выборки для коррекции весовых коэффициентов при одинаковых настройках самой сети и алгоритма ее обучения.

Архитектуры моделей

1. **Однослойный перцептрон:** Простейший тип ИНС, состоящий из одного выходного слоя нейронов. Математически он реализует линейную комбинацию входных сигналов с весами: $s = w_0 + \sum w_i x_i$. Такая структура способна описывать только линейные зависимости.
2. **Многослойный перцептрон (MLP):** Содержит один или несколько скрытых слоев. Каждый нейрон скрытого слоя использует нелинейную **функцию активации**. В работе использована функция **ReLU** ($f(s) = \max(0, s)$), которая позволяет сети «выучивать» сложные нелинейные закономерности.

Алгоритм обучения

Для настройки параметров используется метод обратного распространения ошибки. В качестве оптимизатора применен **Adam** — адаптивный алгоритм, который эффективнее стандартного градиентного спуска (SGD) в задачах со сложным рельефом функции потерь.

Метрики качества

- **MSE (Mean Squared Error):** квадрат ошибки.
- **MAE (Mean Absolute Error):** среднее абсолютное отклонение, показывающее среднюю ошибку в единицах целевой переменной (в долларах).
- **Коэффициент детерминации R^2 :** доля дисперсии зависимой переменной, объясняемая моделью. Значение 1.0 — идеальный прогноз, 0.0 — уровень среднего значения.

1.3. Практическая часть

1.3.1. Описание данных

Первым этапом работы было исследование структуры набора данных «Diamonds».

Первые строки датасета:

	carat	cut	color	clarity	depth	table	price	x	y	z
0	0.23	Ideal	E	SI2	61.5	55.0	326	3.95	3.98	2.43

1	0.21	Premium	E	SI1	59.8	61.0	326	3.89	3.84	2.31
2	0.23	Good	E	VS1	56.9	65.0	327	4.05	4.07	2.31
3	0.29	Premium	I	VS2	62.4	58.0	334	4.20	4.23	2.63
4	0.31	Good	J	SI2	63.3	58.0	335	4.34	4.35	2.75

Общая информация о типах данных:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 53940 entries, 0 to 53939
Data columns (total 10 columns):
#   Column      Non-Null Count  Dtype
---  -
0   carat       53940 non-null  float64
1   cut         53940 non-null  object
2   color       53940 non-null  object
3   clarity     53940 non-null  object
4   depth       53940 non-null  float64
5   table       53940 non-null  float64
6   price       53940 non-null  int64
7   x           53940 non-null  float64
8   y           53940 non-null  float64
9   z           53940 non-null  float64
dtypes: float64(6), int64(1), object(3)
memory usage: 4.1+ MB
```

1.3.2. Предварительный анализ данных (EDA)

Для оценки качества признаков и их распределения были построены следующие графики:




Рис. 1: Распределение целевой переменной Price




Рис. 2: Матрица корреляций

Анализ: На графике распределения видно, что большинство цен сосредоточено в диапазоне до 5000\$.




Рис. 3: Взаимосвязь веса в каратах и стоимости

В ходе анализа были визуализированы распределения признаков и построена матрица корреляций.




Рис. 4: Матрица корреляций признаков

Выявлено, что на тепловой карте подтверждается сильная корреляция (0.86+) цены с весом (carat) и физическими размерами (x, y, z).

1.3.3. Обучение моделей и результаты

Было проведено обучение двух нейронных сетей: однослойного перцептрона и многослойного (MLP) с двумя скрытыми слоями по 64 нейрона. Для обучения использовался оптимизатор Adam. Результаты сравнения моделей на тестовой выборке представлены в таблице ниже.

Модель	MSE	MAE	R ²
Однослойная	3.01e+07	3810.63	-0.9284
Многослойная (MLP)	1.23e+06	617.67	0.9211

Примечание: Отрицательный R^2 у однослойной модели говорит о том, что она предсказывает хуже, чем просто среднее значение по выборке, что подтверждает нелинейность данных. Отрицательное значение R^2 у однослойной модели (-0.9284) математически означает, что модель предсказывает значения хуже, чем если бы мы просто всегда выдавали среднюю цену бриллианта. Это наглядно доказывает, что зависимость цены от характеристик (особенно от каратов) в данном датасете носит выраженный нелинейный характер (например, экспоненциальный), и линейная модель для этой задачи непригодна.




Рис. 5: Сравнение графиков обучения: Однослойная (слева) и Многослойная (справа)

1.4. Выводы по работе

1. В ходе EDA выявлено, что цена бриллианта сильнее всего коррелирует с физическими размерами (x , y , z) и весом (carat). Это объясняется физической природой объекта: объем определяет массу, а масса — ключевой фактор ценообразования.
2. Нормализация данных является важной: без приведения признаков к единому диапазону $[0, 1]$ градиентные алгоритмы могли работать нестабильно из-за разного масштаба цен и карат.
3. Многослойный перцептрон (MLP) показал MAE в 6 раз ниже, чем однослойная модель. Это подтверждает теорию о том, что введение скрытых слоев и функций активации (ReLU) позволяет нейросети моделировать сложные взаимосвязи между цветом, огранкой и ценой, которые невозможно описать прямой линией.
4. Судя по графикам (Рис. 5), многослойная модель сошлась к 10-й эпохе, при этом кривые обучения и валидации находятся близко друг к другу, что говорит об отсутствии переобучения.

2. Лабораторная работа 2. Распознавание символов

2.1. Описание задачи

Целью работы является решение задачи классификации изображений рукописных цифр. Необходимо сравнить работу многослойного перцептрона (MLP) и сверточной нейронной сети (CNN).

2.2. Теоретическая часть

Согласно Слайду 5 Лекции 2, основным недостатком полносвязных сетей при работе с изображениями является “ломка” пространственных отношений. Сверточные сети (CNN) решают эту проблему через:

1. **Свертки (Convolution):** выделение признаков (линий, паттернов).

2. Пулинг (Pooling): уменьшение размерности с сохранением важных данных.

2.3. Практическая часть

2.3.1. Исследование структуры данных

Ниже представлена техническая информация о структуре используемого датасета:

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 42000 entries, 0 to 41999  
Columns: 785 entries, label to pixel783  
dtypes: int64(785)  
memory usage: 251.5 MB
```

Датасет содержит изображения цифр 0-9. Ниже представлены средние значения пикселей для каждого класса, что позволяет увидеть “идеальные” паттерны каждой цифры.




Figure 6: Усредненные изображения цифр

2.3.2. Визуальный анализ (EDA)

Для каждого класса был построен “усредненный” шаблон цифры, позволяющий визуально оценить характерные черты начертания в выборке.




Figure 7: Средние изображения цифр

2.3.3. Влияние количества эпох на точность

В ходе эксперимента оценивалось влияние гиперпараметра «количество эпох» на итоговую точность классификации на тестовой выборке.




Figure 8: Зависимость точности от числа эпох обучения

2.3.4. Результаты и сравнение

Сравнение валидационной точности и потерь для финальных моделей:




Figure 9: Сравнение процесса обучения MLP и CNN

Для детального анализа качества классификации были построены матрицы ошибок. Они показывают, какие цифры модели путают чаще всего.




Figure 10: Матрица ошибок MLP




Figure 11: Матрица ошибок CNN

Детальный отчет классификации для MLP:

	precision	recall	f1-score	support
0	0.93	0.95	0.94	827
1	0.89	0.95	0.92	937
2	0.87	0.87	0.87	835
3	0.86	0.85	0.86	870
4	0.88	0.91	0.89	814
5	0.85	0.76	0.81	759
6	0.93	0.91	0.92	827
7	0.93	0.91	0.92	880
8	0.82	0.83	0.82	813
9	0.86	0.88	0.87	838
accuracy			0.88	8400
macro avg	0.88	0.88	0.88	8400
weighted avg	0.88	0.88	0.88	8400

Детальный отчет классификации для CNN:

	precision	recall	f1-score	support
0	0.95	0.96	0.95	827
1	0.92	0.97	0.94	937
2	0.92	0.89	0.90	835
3	0.89	0.88	0.88	870
4	0.92	0.90	0.91	814
5	0.85	0.82	0.84	759
6	0.94	0.95	0.95	827
7	0.91	0.89	0.90	880
8	0.86	0.86	0.86	813
9	0.84	0.87	0.85	838
accuracy			0.90	8400
macro avg	0.90	0.90	0.90	8400
weighted avg	0.90	0.90	0.90	8400

2.3.6. Тестирование на пользовательских данных

Для проверки обобщающей способности моделей было проведено тестирование на 10 собственных рукописных цифрах, сфотографированных на камеру смартфона. Изображения прошли предварительную обработку: перевод в градации серого, инверсию цвета (для соответствия формату MNIST) и масштабирование до размера 28×28 пикселей.




Figure 12: Результаты распознавания пользовательских фотографий

Результаты теста:

Цифра 0: MLP=2, CNN=3
 Цифра 1: MLP=2, CNN=3
 Цифра 2: MLP=2, CNN=3
 Цифра 3: MLP=3, CNN=3
 Цифра 4: MLP=2, CNN=3
 Цифра 5: MLP=2, CNN=3
 Цифра 6: MLP=2, CNN=3
 Цифра 7: MLP=2, CNN=3
 Цифра 8: MLP=2, CNN=3
 Цифра 9: MLP=3, CNN=3

2.4. Выводы по работе

1. Сверточная сеть (CNN) даже с минимальным количеством фильтров показала более стабильное обучение в сравнении с MLP.
2. Анализ матрицы ошибок подтвердил высокую точность классификации для всех классов цифр.
3. Использование графиков “Ошибки от количества эпох” позволило обоснованно выбрать момент остановки обучения.