

Министерство науки и высшего образования Российской Федерации
Российский химико-технологический университет имени Д.И.
Менделеева

Факультет цифровых технологий и химического инжиниринга
Кафедра информационных компьютерных технологий

ОТЧЕТ
ПО ЛАБОРАТОРНОМУ ПРАКТИКУМУ

«Методы искусственного интеллекта»

Вариант №1

ВЫПОЛНИЛ: студент группы КС-46 Золотухин А.А.
ПРОВЕРИЛ: ассистент Макляев И.В.

Москва

2026

СОДЕРЖАНИЕ

1. Лабораторная работа 1. Решение задачи регрессии	3
1.1. Цель работы. Задача. Вариант задания	3
1.2. Теоретическая часть	3
Архитектуры моделей	3
Алгоритм обучения	3
Метрики качества	3
1.3. Практическая часть	3
1.3.1. Описание данных	3
1.3.2. Предварительный анализ данных (EDA)	4
1.3.3. Обучение моделей и результаты	5
1.4. Выводы по работе	6
2. Лабораторная работа 2. Распознавание символов	6
2.1. Описание задачи	6
2.2. Теоретическая часть	6
2.3. Практическая часть	7
2.1. Цель работы. Задача	7
2.2. Теоретическая часть	7
2.3. Практическая часть	7
2.3.1. Подготовка данных	7
2.3.2. Архитектуры моделей	7
2.3.3. Обучение моделей	8
2.3.4. Проверка на собственных изображениях	8
2.4. Выводы по работе	8

1. Лабораторная работа 1. Решение задачи регрессии

1.1. Цель работы. Задача. Вариант задания

Цель работы: приобретение навыков анализа данных, проектирования и обучения искусственных нейронных сетей для решения задач аппроксимации и регрессии с использованием фреймворка Keras.

Задача: На основе набора данных «Diamonds» построить модель прогнозирования рыночной стоимости бриллианта в зависимости от его характеристик.

Вариант задания: Вариант 1 (Задание на регрессию).

1.2. Теоретическая часть

Искусственные нейронные сети – это математический аппарат, основанный на аналогиях с функционированием центральной нервной системы и предназначенный для решения широкого круга задач, таких, как распознавание образов, классификация, кластеризация и аппроксимация данных, прогнозирование временных рядов, адаптивное управление и многих других.

Архитектура нейронной сети – совокупность, объединяющая принципы организации и функционирования нейронной сети и отдельных искусственных нейронов, алгоритмы и расчетные соотношения для ее обучения.

Структура нейронной сети - количество слоев, нейронов в каждом слое, а также количество внешних входных и выходных переменных.

Обучение нейронной сети представляет собой процедуру точного или итерационного расчета всех ее весовых коэффициентов, соединяющих внешние входы с нейронами и нейроны между собой.

Под **эпохой обучения** понимается цикл однократного предъявления (как правило, в случайном порядке) всех примеров обучающей выборки для коррекции весовых коэффициентов при одинаковых настройках самой сети и алгоритма ее обучения.

Архитектуры моделей

1. **Однослойный перцептрон:** Простейший тип ИНС, состоящий из одного выходного слоя нейронов. Математически он реализует линейную комбинацию входных сигналов с весами: $s = w_0 + \sum w_i x_i$. Такая структура способна описывать только линейные зависимости.
2. **Многослойный перцептрон (MLP):** Содержит один или несколько скрытых слоев. Каждый нейрон скрытого слоя использует нелинейную **функцию активации**. В работе использована функция **ReLU** ($f(s) = \max(0, s)$), которая позволяет сети «выучивать» сложные нелинейные закономерности.

Алгоритм обучения

Для настройки параметров используется метод обратного распространения ошибки. В качестве оптимизатора применен **Adam** — адаптивный алгоритм, который эффективнее стандартного градиентного спуска (SGD) в задачах со сложным рельефом функции потерь.

Метрики качества

- **MSE (Mean Squared Error):** квадрат ошибки.
- **MAE (Mean Absolute Error):** среднее абсолютное отклонение, показывающее среднюю ошибку в единицах целевой переменной (в долларах).
- **Коэффициент детерминации R^2 :** доля дисперсии зависимой переменной, объясняемая моделью. Значение 1.0 — идеальный прогноз, 0.0 — уровень среднего значения.

1.3. Практическая часть

1.3.1. Описание данных

Первым этапом работы было исследование структуры набора данных «Diamonds».

Первые строки датасета:

	carat	cut	color	clarity	depth	table	price	x	y	z
0	0.23	Ideal	E	SI2	61.5	55.0	326	3.95	3.98	2.43

1	0.21	Premium	E	SI1	59.8	61.0	326	3.89	3.84	2.31
2	0.23	Good	E	VS1	56.9	65.0	327	4.05	4.07	2.31
3	0.29	Premium	I	VS2	62.4	58.0	334	4.20	4.23	2.63
4	0.31	Good	J	SI2	63.3	58.0	335	4.34	4.35	2.75

Общая информация о типах данных:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 53940 entries, 0 to 53939
Data columns (total 10 columns):
#   Column      Non-Null Count  Dtype
---  -
0   carat       53940 non-null  float64
1   cut         53940 non-null  object
2   color       53940 non-null  object
3   clarity     53940 non-null  object
4   depth       53940 non-null  float64
5   table       53940 non-null  float64
6   price       53940 non-null  int64
7   x           53940 non-null  float64
8   y           53940 non-null  float64
9   z           53940 non-null  float64
dtypes: float64(6), int64(1), object(3)
memory usage: 4.1+ MB
```

1.3.2. Предварительный анализ данных (EDA)

Для оценки качества признаков и их распределения были построены следующие графики:



Рис. 1: Распределение целевой переменной Price




Рис. 2: Матрица корреляций

Анализ: На графике распределения видно, что большинство цен сосредоточено в диапазоне до 5000\$.




Рис. 3: Взаимосвязь веса в каратах и стоимости

В ходе анализа были визуализированы распределения признаков и построена матрица корреляций.




Рис. 4: Матрица корреляций признаков

Выявлено, что на тепловой карте подтверждается сильная корреляция (0.86+) цены с весом (carat) и физическими размерами (x, y, z).

1.3.3. Обучение моделей и результаты

Было проведено обучение двух нейронных сетей: однослойного перцептрона и многослойного (MLP) с двумя скрытыми слоями по 64 нейрона. Для обучения использовался оптимизатор Adam. Результаты сравнения моделей на тестовой выборке представлены в таблице ниже.

Модель	MSE	MAE	R ²
Однослойная	3.01e+07	3810.63	-0.9284
Многослойная (MLP)	1.23e+06	617.67	0.9211

Примечание: Отрицательный R^2 у однослойной модели говорит о том, что она предсказывает хуже, чем просто среднее значение по выборке, что подтверждает нелинейность данных. Отрицательное значение R^2 у однослойной модели (-0.9284) математически означает, что модель предсказывает значения хуже, чем если бы мы просто всегда выдавали среднюю цену бриллианта. Это наглядно доказывает, что зависимость цены от характеристик (особенно от каратов) в данном датасете носит выраженный нелинейный характер (например, экспоненциальный), и линейная модель для этой задачи непригодна.




Рис. 5: Сравнение графиков обучения: Однослойная (слева) и Многослойная (справа)

1.4. Выводы по работе

1. В ходе EDA выявлено, что цена бриллианта сильнее всего коррелирует с физическими размерами (x , y , z) и весом (carat). Это объясняется физической природой объекта: объем определяет массу, а масса — ключевой фактор ценообразования.
2. Нормализация данных является важной: без приведения признаков к единому диапазону $[0, 1]$ градиентные алгоритмы могли работать нестабильно из-за разного масштаба цен и карат.
3. Многослойный перцептрон (MLP) показал MAE в 6 раз ниже, чем однослойная модель. Это подтверждает теорию о том, что введение скрытых слоев и функций активации (ReLU) позволяет нейросети моделировать сложные взаимосвязи между цветом, огранкой и ценой, которые невозможно описать прямой линией.
4. Судя по графикам (Рис. 5), многослойная модель сошлась к 10-й эпохе, при этом кривые обучения и валидации находятся близко друг к другу, что говорит об отсутствии переобучения.

2. Лабораторная работа 2. Распознавание символов

2.1. Описание задачи

Целью работы является решение задачи классификации изображений рукописных цифр. Необходимо сравнить работу многослойного перцептрона (MLP) и сверточной нейронной сети (CNN).

2.2. Теоретическая часть

Согласно Слайду 5 Лекции 2, основным недостатком полносвязных сетей при работе с изображениями является “ломка” пространственных отношений. Сверточные сети (CNN) решают эту проблему через:

1. **Свертки (Convolution):** выделение признаков (линий, паттернов).

2. Пулинг (Pooling): уменьшение размерности с сохранением важных данных.

2.3. Практическая часть

2.1. Цель работы. Задача

Цель работы: изучить применение полносвязных и свёрточных нейронных сетей для решения задачи классификации изображений. **Задача:** по набору данных рукописных цифр построить две модели распознавания символов: многослойный перцептрон (MLP) и свёрточную нейронную сеть (CNN), сравнить их качество и протестировать модель на собственных изображениях цифр.

2.2. Теоретическая часть

Задача классификации заключается в определении класса объекта по его признакам. В данной лабораторной работе объектом является изображение цифры размером 28×28 , а классом — одна из цифр от 0 до 9.

Многослойный перцептрон (MLP) представляет собой полносвязную нейронную сеть, в которой входное изображение разворачивается в вектор признаков. Далее этот вектор проходит через несколько линейных слоёв и нелинейных функций активации. Такой подход прост в реализации, однако при разворачивании изображения теряются пространственные связи между пикселями.

Свёрточная нейронная сеть (CNN) учитывает двумерную структуру изображения. Свёрточные слои выделяют характерные локальные признаки: границы, штрихи, фрагменты контуров. После этого операция **max pooling** уменьшает размерность карт признаков и делает сеть менее чувствительной к небольшим смещениям изображения. Благодаря этому CNN обычно показывает более высокое качество на задачах распознавания изображений.

В качестве функции потерь в работе использована **кросс-энтропия (CrossEntropyLoss)**, поскольку решается задача многоклассовой классификации. Для настройки весов сети применён оптимизатор **Adam**, обеспечивающий быструю и устойчивую сходимость. Для уменьшения переобучения в архитектурах использовались слои **Dropout**.

Основной метрикой качества в работе является **Accuracy** — доля правильно распознанных объектов:

$$\text{Accuracy} = \frac{\text{число верных предсказаний}}{\text{общее число объектов}}$$

2.3. Практическая часть

2.3.1. Подготовка данных

В качестве обучающего набора использовался датасет рукописных цифр, представленный в виде таблицы `train.csv`. Каждый объект содержит метку класса `label` и 784 признака, соответствующих яркостям пикселей изображения размером 28×28 .

Перед обучением данные были разделены на обучающую и валидационную выборки в отношении 80/20. Значения пикселей были нормализованы к диапазону $[0, 1]$, что повышает устойчивость обучения нейронной сети.

Информация о разбиении выборки сохраняется в файл `lab2/assets/dataset_info.txt`.

Информация о данных
Размер обучающей выборки: (33600, 784)
Размер валидационной выборки: (8400, 784)
Количество классов: 10
Классы: [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]

2.3.2. Архитектуры моделей

В работе были реализованы две модели:

1. **MLP:** входное изображение размером 28×28 разворачивалось в вектор длины 784, после чего подавалось на полносвязную сеть с двумя скрытыми слоями и функцией активации ReLU.

2. **CNN:** изображение подавалось на два свёрточных слоя, после каждого из которых применялись ReLU и max pooling. Далее признаки разворачивались в вектор и поступали на полносвязную часть сети для окончательной классификации.

Таким образом, MLP использует только числовое представление изображения, а CNN учитывает пространственную структуру данных.

2.3.3. Обучение моделей

Обе модели обучались с использованием оптимизатора Adam. Для контроля качества использовалась валидационная выборка. На каждой эпохе фиксировались значения функции потерь и точности.

Графики процесса обучения представлены ниже.




Рис. 6: Графики обучения модели MLP




Рис. 7: Графики обучения модели CNN

Итоговые результаты обучения сохраняются в файл `lab2/assets/training_summary.txt`.

```
Итоговые результаты обучения
Лучшая точность MLP на валидации: 0.9779
Лучшая точность CNN на валидации: 0.9901
Файл весов MLP: /home/corgi/git-repos/ai-methods/labs/lab2/assets/models/mlp_best.pth
Файл весов CNN: /home/corgi/git-repos/ai-methods/labs/lab2/assets/models/cnn_best.pth
```

2.3.4. Проверка на собственных изображениях

После обучения лучшая версия каждой модели была протестирована на собственных изображениях цифр, размещённых в папке `lab2/data/my_digits`. Изображения предварительно приводились к оттенкам серого, масштабировались до размера 28×28 и нормализовались.

Результаты предсказания были сохранены в файл `lab2/assets/my_digits_predictions.txt`.

```
Предсказания MLP
0.png -> 0
1.png -> 2
2.png -> 2
3.png -> 3
4.png -> 4
5.png -> 5
6.png -> 6
7.png -> 2
8.png -> 8
9.png -> 9

Предсказания CNN
0.png -> 0
1.png -> 1
2.png -> 2
3.png -> 3
4.png -> 4
5.png -> 5
6.png -> 5
7.png -> 7
8.png -> 8
9.png -> 9
```

2.4. Выводы по работе

1. В ходе лабораторной работы были реализованы и обучены две модели для распознавания рукописных цифр: многослойный перцептрон и свёрточная нейронная сеть.
2. Полносвязная модель MLP показала хорошее качество классификации, однако свёрточная сеть оказалась более приспособленной к обработке изображений.
3. CNN продемонстрировала более высокую точность на валидационной выборке, поскольку свёрточные слои позволяют выделять локальные особенности изображения и сохранять пространственные связи между пикселями.
4. Дополнительная проверка на собственных изображениях цифр подтвердила практическую применимость обученной модели к реальным данным.