

Министерство науки и высшего образования Российской Федерации
Российский химико-технологический университет имени Д.И.
Менделеева

Факультет цифровых технологий и химического инжиниринга
Кафедра информационных компьютерных технологий

ОТЧЕТ
ПО ЛАБОРАТОРНОМУ ПРАКТИКУМУ
«Методы искусственного интеллекта»

Вариант №1

ВЫПОЛНИЛ: студент группы КС-46 Золотухин А.А.
ПРОВЕРИЛ: ассистент Макляев И.В.

Москва

2026

СОДЕРЖАНИЕ

1. Лабораторная работа 1. Решение задачи регрессии	3
1.1. Цель работы. Задача. Вариант задания	3
1.2. Теоретическая часть	3
Архитектуры моделей	3
Алгоритм обучения	3
Метрики качества	3
1.3. Практическая часть	3
1.3.1. Описание данных	3
1.3.2. Предварительный анализ данных (EDA)	4
1.3.3. Обучение моделей и результаты	5
1.4. Выводы по работе	6
2. Лабораторная работа 2. Распознавание символов	6
2.1. Описание задачи	6
2.2. Теоретическая часть	6
2.3. Практическая часть	7
2.1. Цель работы. Задача	7
2.2. Теоретическая часть	7
2.3. Практическая часть	7
2.3.1. Подготовка данных	7
2.3.2. Архитектуры моделей	7
2.3.3. Обучение моделей	8
2.3.4. Анализ ошибок моделей	8
2.3.5. Проверка на собственных изображениях	8
2.4. Выводы по работе	9
3. Лабораторная работа 3. Анализ устойчивости CNN и визуализация признаков	10
3.1. Цель работы. Задача	10
3.2. Теоретическая часть	10
3.3. Практическая часть	10
3.3.1. Baseline-модель	10
3.3.2. CNN с аугментированным обучением	10
3.3.3. Проверка на собственных изображениях	11
3.3.4. Визуализация карт признаков	13
3.4. Выводы по работе	13
ВЫВОДЫ	13
СПИСОК ЛИТЕРАТУРЫ	14

1. Лабораторная работа 1. Решение задачи регрессии

1.1. Цель работы. Задача. Вариант задания

Цель работы: приобретение навыков анализа данных, проектирования и обучения искусственных нейронных сетей для решения задач аппроксимации и регрессии с использованием фреймворка Keras.

Задача: На основе набора данных «Diamonds» построить модель прогнозирования рыночной стоимости бриллианта в зависимости от его характеристик.

Вариант задания: Вариант 1 (Задание на регрессию).

1.2. Теоретическая часть

Искусственные нейронные сети – это математический аппарат, основанный на аналогиях с функционированием центральной нервной системы и предназначенный для решения широкого круга задач, таких, как распознавание образов, классификация, кластеризация и аппроксимация данных, прогнозирование временных рядов, адаптивное управление и многих других.

Архитектура нейронной сети – совокупность, объединяющая принципы организации и функционирования нейронной сети и отдельных искусственных нейронов, алгоритмы и расчетные соотношения для ее обучения.

Структура нейронной сети - количество слоев, нейронов в каждом слое, а также количество внешних входных и выходных переменных.

Обучение нейронной сети представляет собой процедуру точного или итерационного расчета всех ее весовых коэффициентов, соединяющих внешние входы с нейронами и нейроны между собой.

Под **эпохой обучения** понимается цикл однократного предъявления (как правило, в случайном порядке) всех примеров обучающей выборки для коррекции весовых коэффициентов при одинаковых настройках самой сети и алгоритма ее обучения.

Архитектуры моделей

1. **Однослойный перцептрон:** Простейший тип ИНС, состоящий из одного выходного слоя нейронов. Математически он реализует линейную комбинацию входных сигналов с весами: $s = w_0 + \sum w_i x_i$. Такая структура способна описывать только линейные зависимости.
2. **Многослойный перцептрон (MLP):** Содержит один или несколько скрытых слоев. Каждый нейрон скрытого слоя использует нелинейную **функцию активации**. В работе использована функция **ReLU** ($f(s) = \max(0, s)$), которая позволяет сети «выучивать» сложные нелинейные закономерности.

Алгоритм обучения

Для настройки параметров используется метод обратного распространения ошибки. В качестве оптимизатора применен **Adam** — адаптивный алгоритм, который эффективнее стандартного градиентного спуска (SGD) в задачах со сложным рельефом функции потерь.

Метрики качества

- **MSE (Mean Squared Error):** квадрат ошибки.
- **MAE (Mean Absolute Error):** среднее абсолютное отклонение, показывающее среднюю ошибку в единицах целевой переменной (в долларах).
- **Коэффициент детерминации R^2 :** доля дисперсии зависимой переменной, объясняемая моделью. Значение 1.0 — идеальный прогноз, 0.0 — уровень среднего значения.

1.3. Практическая часть

1.3.1. Описание данных

Первым этапом работы было исследование структуры набора данных «Diamonds».

Первые строки датасета:

	carat	cut	color	clarity	depth	table	price	x	y	z
0	0.23	Ideal	E	SI2	61.5	55.0	326	3.95	3.98	2.43

1	0.21	Premium	E	SI1	59.8	61.0	326	3.89	3.84	2.31
2	0.23	Good	E	VS1	56.9	65.0	327	4.05	4.07	2.31
3	0.29	Premium	I	VS2	62.4	58.0	334	4.20	4.23	2.63
4	0.31	Good	J	SI2	63.3	58.0	335	4.34	4.35	2.75

Общая информация о типах данных:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 53940 entries, 0 to 53939
Data columns (total 10 columns):
#   Column      Non-Null Count  Dtype
---  -
0   carat       53940 non-null  float64
1   cut         53940 non-null  object
2   color       53940 non-null  object
3   clarity     53940 non-null  object
4   depth       53940 non-null  float64
5   table       53940 non-null  float64
6   price       53940 non-null  int64
7   x           53940 non-null  float64
8   y           53940 non-null  float64
9   z           53940 non-null  float64
dtypes: float64(6), int64(1), object(3)
memory usage: 4.1+ MB
```

1.3.2. Предварительный анализ данных (EDA)

Для оценки качества признаков и их распределения были построены следующие графики:



Рис. 1: Распределение целевой переменной Price




Рис. 2: Матрица корреляций

Анализ: На графике распределения видно, что большинство цен сосредоточено в диапазоне до 5000\$.




Рис. 3: Взаимосвязь веса в каратах и стоимости

В ходе анализа были визуализированы распределения признаков и построена матрица корреляций.




Рис. 4: Матрица корреляций признаков

Выявлено, что на тепловой карте подтверждается сильная корреляция (0.86+) цены с весом (carat) и физическими размерами (x, y, z).

1.3.3. Обучение моделей и результаты

Было проведено обучение двух нейронных сетей: однослойного перцептрона и многослойного (MLP) с двумя скрытыми слоями по 64 нейрона. Для обучения использовался оптимизатор Adam. Результаты сравнения моделей на тестовой выборке представлены в таблице ниже.

Модель	MSE	MAE	R ²
Однослойная	3.01e+07	3810.63	-0.9284
Многослойная (MLP)	1.23e+06	617.67	0.9211

Примечание: Отрицательный R^2 у однослойной модели говорит о том, что она предсказывает хуже, чем просто среднее значение по выборке, что подтверждает нелинейность данных. Отрицательное значение R^2 у однослойной модели (-0.9284) математически означает, что модель предсказывает значения хуже, чем если бы мы просто всегда выдавали среднюю цену бриллианта. Это наглядно доказывает, что зависимость цены от характеристик (особенно от каратов) в данном датасете носит выраженный нелинейный характер (например, экспоненциальный), и линейная модель для этой задачи непригодна.




Рис. 5: Сравнение графиков обучения: Однослойная (слева) и Многослойная (справа)

1.4. Выводы по работе

1. В ходе EDA выявлено, что цена бриллианта сильнее всего коррелирует с физическими размерами (x , y , z) и весом (carat). Это объясняется физической природой объекта: объем определяет массу, а масса — ключевой фактор ценообразования.
2. Нормализация данных является важной: без приведения признаков к единому диапазону $[0, 1]$ градиентные алгоритмы могли работать нестабильно из-за разного масштаба цен и карат.
3. Многослойный перцептрон (MLP) показал MAE в 6 раз ниже, чем однослойная модель. Это подтверждает теорию о том, что введение скрытых слоев и функций активации (ReLU) позволяет нейросети моделировать сложные взаимосвязи между цветом, огранкой и ценой, которые невозможно описать прямой линией.
4. Судя по графикам (Рис. 5), многослойная модель сошлась к 10-й эпохе, при этом кривые обучения и валидации находятся близко друг к другу, что говорит об отсутствии переобучения.

2. Лабораторная работа 2. Распознавание символов

2.1. Описание задачи

Целью работы является решение задачи классификации изображений рукописных цифр. Необходимо сравнить работу многослойного перцептрона (MLP) и сверточной нейронной сети (CNN).

2.2. Теоретическая часть

Согласно Слайду 5 Лекции 2, основным недостатком полносвязных сетей при работе с изображениями является “ломка” пространственных отношений. Сверточные сети (CNN) решают эту проблему через:

1. **Свертки (Convolution):** выделение признаков (линий, паттернов).

2. Пулинг (Pooling): уменьшение размерности с сохранением важных данных.

2.3. Практическая часть

2.1. Цель работы. Задача

Цель работы: изучить применение полносвязных и свёрточных нейронных сетей для решения задачи классификации изображений. **Задача:** по набору данных рукописных цифр построить две модели распознавания символов: многослойный перцептрон (MLP) и свёрточную нейронную сеть (CNN), сравнить их качество и протестировать модель на собственных изображениях цифр.

2.2. Теоретическая часть

Задача классификации заключается в определении класса объекта по его признакам. В данной лабораторной работе объектом является изображение цифры размером 28×28 , а классом — одна из цифр от 0 до 9.

Многослойный перцептрон (MLP) представляет собой полносвязную нейронную сеть, в которой входное изображение разворачивается в вектор признаков. Далее этот вектор проходит через несколько линейных слоёв и нелинейных функций активации. Такой подход прост в реализации, однако при разворачивании изображения теряются пространственные связи между пикселями.

Свёрточная нейронная сеть (CNN) учитывает двумерную структуру изображения. Свёрточные слои выделяют характерные локальные признаки: границы, штрихи, фрагменты контуров. После этого операция **max pooling** уменьшает размерность карт признаков и делает сеть менее чувствительной к небольшим смещениям изображения. Благодаря этому CNN обычно показывает более высокое качество на задачах распознавания изображений.

В качестве функции потерь в работе использована **кросс-энтропия (CrossEntropyLoss)**, поскольку решается задача многоклассовой классификации. Для настройки весов сети применён оптимизатор **Adam**, обеспечивающий быструю и устойчивую сходимость. Для уменьшения переобучения в архитектурах использовались слои **Dropout**.

Основной метрикой качества в работе является **Accuracy** — доля правильно распознанных объектов:

$$\text{Accuracy} = \frac{\text{число верных предсказаний}}{\text{общее число объектов}}$$

2.3. Практическая часть

2.3.1. Подготовка данных

В качестве обучающего набора использовался датасет рукописных цифр, представленный в виде таблицы `train.csv`. Каждый объект содержит метку класса `label` и 784 признака, соответствующих яркостям пикселей изображения размером 28×28 .

Перед обучением данные были разделены на обучающую и валидационную выборки в отношении 80/20. Значения пикселей были нормализованы к диапазону $[0, 1]$, что повышает устойчивость обучения нейронной сети.

Информация о разбиении выборки сохраняется в файл `lab2/assets/dataset_info.txt`.

Информация о данных
Размер обучающей выборки: (33600, 784)
Размер валидационной выборки: (8400, 784)
Количество классов: 10
Классы: [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]

2.3.2. Архитектуры моделей

В лабораторной работе были реализованы две архитектуры:

1. **MLP** — полносвязная нейронная сеть с двумя скрытыми слоями и функцией активации ReLU.
2. **CNN** — свёрточная сеть, состоящая из трёх свёрточных слоёв, двух операций max pooling и двух полносвязных слоёв.

Для MLP изображение сначала разворачивалось в вектор, а для CNN сохранялась двумерная структура изображения, что позволяло учитывать локальные пространственные особенности цифр.

2.3.3. Обучение моделей

Обе модели обучались с использованием оптимизатора Adam. Для контроля качества использовалась валидационная выборка. На каждой эпохе фиксировались значения функции потерь и точности.

Графики процесса обучения представлены ниже.




Рис. 6: Графики обучения модели MLP




Рис. 7: Графики обучения модели CNN

Итоговые результаты обучения сохраняются в файл lab2/assets/training_summary.txt.

Итоговые результаты обучения

Лучшая точность MLP на валидации: 0.9763

Лучшая точность CNN на валидации: 0.9902

Файл весов MLP: /home/corgi/git-reps/ai-methods/labs/lab2/assets/models/mlp_best.pth

Файл весов CNN: /home/corgi/git-reps/ai-methods/labs/lab2/assets/models/cnn_best.pth

2.3.4. Анализ ошибок моделей

Для более детальной оценки качества были построены матрицы ошибок (**confusion matrix**) для обеих моделей. Они позволяют определить, какие цифры распознаются правильно, а какие чаще всего путаются между собой.




Рис. 8: Матрица ошибок модели MLP




Рис. 9: Матрица ошибок модели CNN

По матрицам ошибок можно сделать вывод, что свёрточная сеть ошибается реже и лучше различает похожие по написанию цифры по сравнению с MLP.

2.3.5. Проверка на собственных изображениях




Рис. 10: Собственные изображения цифр и предсказания моделей MLP и CNN

После обучения лучшая версия каждой модели была протестирована на собственных изображениях цифр, размещённых в папке `lab2/data/my_digits`. Изображения предварительно приводились к оттенкам серого, масштабировались до размера 28×28 и нормализовались.

Результаты предсказания были сохранены в файл `lab2/assets/my_digits_predictions.txt`.

Предсказания MLP

```
0.png -> 0
1.png -> 2
2.png -> 2
3.png -> 3
4.png -> 4
5.png -> 5
6.png -> 6
7.png -> 2
8.png -> 8
9.png -> 9
```

Предсказания CNN

```
0.png -> 0
1.png -> 1
2.png -> 2
3.png -> 3
4.png -> 4
5.png -> 5
6.png -> 6
7.png -> 7
8.png -> 8
9.png -> 9
```

2.4. Выводы по работе

1. В ходе лабораторной работы были реализованы и обучены две модели для распознавания рукописных цифр: многослойный перцептрон и свёрточная нейронная сеть.
2. Полносвязная модель MLP показала хорошее качество классификации, однако свёрточная сеть оказалась более приспособленной к обработке изображений.
3. CNN продемонстрировала более высокую точность на валидационной выборке, поскольку свёрточные слои позволяют выделять локальные особенности изображения и сохранять пространственные связи между пикселями.
4. Дополнительная проверка на собственных изображениях цифр подтвердила практическую применимость обученной модели к реальным данным.

3. Лабораторная работа 3. Анализ устойчивости CNN и визуализация признаков

3.1. Цель работы. Задача

Цель работы: исследовать устойчивость свёрточной нейронной сети к аугментациям входных данных и изучить внутренние представления, формируемые свёрточными слоями.

Задача: на основе данных из лабораторной работы 2:

1. протестировать обученную CNN на аугментированной выборке и на собственных изображениях;
2. визуализировать карты признаков после свёрточных слоёв и pooling;
3. обучить CNN на аугментированных данных;
4. сравнить качество baseline-модели и модели, обученной с аугментацией.

3.2. Теоретическая часть

Аугментация данных — это искусственное расширение исходного датасета за счёт преобразования изображений: поворотов, сдвигов, изменения масштаба, перспективных искажений и других операций. Она позволяет повысить устойчивость модели к вариативности входных данных и уменьшить переобучение.

Карты признаков (feature maps) — это выходы свёрточных слоёв. Каждый канал карты признаков соответствует одному фильтру и показывает, насколько сильно данный фильтр реагирует на различные участки изображения. На ранних слоях сеть обычно выделяет простые элементы: края, линии, дуги. На более глубоких слоях формируются более сложные и абстрактные признаки.

Pooling уменьшает размерность карт признаков и сохраняет наиболее важную информацию, делая представление более компактным.

3.3. Практическая часть

3.3.1. Baseline-модель

В качестве исходной модели была использована свёрточная нейронная сеть без аугментации обучающих данных. Сначала модель была обучена на обычной обучающей выборке, затем протестирована как на обычной валидации, так и на аугментированной валидации.




Рис. 11: Графики обучения baseline CNN




Рис. 12: Матрица ошибок baseline CNN на аугментированной валидации

3.3.2. CNN с аугментированным обучением

Далее была обучена аналогичная архитектура CNN, но уже с аугментацией обучающих данных. Это позволило оценить, как аугментация влияет на устойчивость модели к искажённым входным изображениям.




Рис. 13: Графики обучения CNN с аугментацией




Рис. 14: Матрица ошибок CNN с аугментацией на аугментированной валидации

Сводные численные результаты экспериментов сохранены в файл `lab3/assets/lab3_summary.txt`.

Лабораторная работа 3

Baseline CNN на обычной валидации

accuracy: 0.9899
precision: 0.9898
recall: 0.9897
f1: 0.9897

Baseline CNN на аугментированной валидации

accuracy: 0.4418
precision: 0.4552
recall: 0.4412
f1: 0.4402

CNN с аугментацией на обычной валидации

accuracy: 0.4282
precision: 0.4336
recall: 0.4272
f1: 0.4261

CNN с аугментацией на аугментированной валидации

accuracy: 0.4296
precision: 0.4391
recall: 0.4289
f1: 0.4282




Рис. 15: Примеры изображений из валидационной выборки до и после сильной аугментации

3.3.3. Проверка на собственных изображениях

Обе модели были дополнительно протестированы на собственных изображениях цифр, а также на их аугментированных версиях. Это позволило оценить, насколько хорошо каждая модель переносится на реальные данные, не входившие в исходный датасет.




Рис. 16: Сравнение предсказаний baseline CNN и CNN с аугментацией на обычных и аугментированных собственных изображениях

Результаты сохранены в файл lab3/assets/my_numbers_comparison.txt.

```
Baseline CNN
0.png | обычное -> 0
0.png | аугментированное -> 9
1.png | обычное -> 3
1.png | аугментированное -> 3
2.png | обычное -> 2
2.png | аугментированное -> 2
3.png | обычное -> 3
3.png | аугментированное -> 3
4.png | обычное -> 4
4.png | аугментированное -> 2
5.png | обычное -> 5
5.png | аугментированное -> 3
6.png | обычное -> 5
6.png | аугментированное -> 3
7.png | обычное -> 7
7.png | аугментированное -> 5
8.png | обычное -> 8
8.png | аугментированное -> 3
```

```

9.png | обычное -> 9
9.png | аугментированное -> 8

CNN с аугментацией
0.png | обычное -> 0
0.png | аугментированное -> 6
1.png | обычное -> 1
1.png | аугментированное -> 4
2.png | обычное -> 2
2.png | аугментированное -> 2
3.png | обычное -> 3
3.png | аугментированное -> 3
4.png | обычное -> 4
4.png | аугментированное -> 3
5.png | обычное -> 5
5.png | аугментированное -> 5
6.png | обычное -> 6
6.png | аугментированное -> 5
7.png | обычное -> 7
7.png | аугментированное -> 3
8.png | обычное -> 8
8.png | аугментированное -> 8
9.png | обычное -> 9
9.png | аугментированное -> 9

```

3.3.4. Визуализация карт признаков

Для нескольких собственных изображений были сохранены карты признаков после:

- первого свёрточного слоя (conv1);
- второго свёрточного слоя (conv2);
- первого pooling (pool1);
- второго pooling (pool2).

Эти изображения позволяют проследить, как сеть последовательно преобразует исходное изображение в набор всё более абстрактных признаков.

Папки с визуализациями расположены по адресам:

- lab3/assets/feature_maps/baseline/...
- lab3/assets/feature_maps/augmented/...

3.4. Выводы по работе

1. Baseline CNN показала высокое качество на обычной валидации, однако её устойчивость на аугментированных данных оказалась ниже.
2. CNN, обученная на аугментированных данных, продемонстрировала более стабильное качество на искажённых изображениях.
3. Это подтверждает, что аугментация улучшает способность модели к обобщению и повышает устойчивость к изменениям входных данных.
4. Визуализация feature maps показала, что ранние свёрточные слои выделяют локальные элементы изображения, а более глубокие формируют более сложные и содержательные признаки.

ВЫВОДЫ

В ходе выполнения лабораторных работ по дисциплине «Методы искусственного интеллекта» были изучены и практически реализованы основные подходы к построению и обучению нейронных сетей для решения задач регрессии и классификации.

В первой лабораторной работе были исследованы методы построения однослойной и многослойной полносвязных нейронных сетей для задачи регрессии. Было показано, что многослойный перцептрон значительно превосходит линейную модель при описании сложных нелинейных зависимостей в реальных данных.

Во второй лабораторной работе были реализованы модели MLP и CNN для распознавания рукописных цифр. Проведённое сравнение подтвердило, что свёрточные нейронные сети лучше подходят для обработки изображений, поскольку позволяют учитывать пространственные особенности входных данных и выделять локальные признаки.

В третьей лабораторной работе была исследована устойчивость свёрточной нейронной сети к аугментациям входных изображений. Было установлено, что обучение на аугментированных данных существенно повышает качество модели на искажённых изображениях и улучшает её способность к обобщению. Дополнительно была выполнена визуализация карт признаков, что позволило проследить переход от простых локальных признаков к более сложным и абстрактным представлениям.

Таким образом, в рамках выполненных работ были получены практические навыки подготовки данных, построения архитектур нейронных сетей, выбора функций потерь и оптимизаторов, анализа метрик качества и интерпретации внутренних представлений моделей. Полученные результаты подтверждают эффективность современных методов глубокого обучения при решении прикладных задач анализа данных и компьютерного зрения.

СПИСОК ЛИТЕРАТУРЫ