Министерство науки и высшего образования Российской Федерации

Российский химико-технологический университет имени Д.И. Менделеева

Факультет цифровых технологий и химического инжиниринга

Кафедра информационных компьютерных технологий

ОТЧЕТ

ПО ЛАБОРАТОРНОМУ ПРАКТИКУМУ

«Методы искусственного интеллекта»

Вариант №1

ВЫПОЛНИЛ: студент группы КС-46 Золотухин А.А.

ПРОВЕРИЛ: ассистент Макляев И.В.

Москва

2026

СОДЕРЖАНИЕ

1. Лабораторная работа 1. Решение задачи регрессии . . . 3
1.1. Цель работы. Задача. Вариант задания . . . 3
1.2. Теоретическая часть . . . 3
Архитектуры моделей . . . 3
Алгоритм обучения . . . 3
Метрики качества . . . 3
1.3. Практическая часть . . . 3
1.3.1. Описание данных . . . 3
1.3.2. Предварительный анализ данных (EDA) . . . 4
1.3.3. Обучение моделей и результаты . . . 5
1.4. Выводы по работе . . . 6

1. Лабораторная работа 1. Решение задачи регрессии

1.1. Цель работы. Задача. Вариант задания

Цель работы: приобретение навыков анализа данных, проектирования и обучения искусственных нейронных сетей для решения задач аппроксимации и регрессии с использованием фреймворка Keras.

Задача: На основе набора данных «Diamonds» построить модель прогнозирования рыночной стоимости бриллианта в зависимости от его характеристик.

Вариант задания: Вариант 1 (Задание на регрессию).

1.2. Теоретическая часть

Искусственные нейронные сети – это математический аппарат, основанный на аналогиях с функционированием центральной нервной системы и предназначенный для решения широкого круга задач, таких, как распознавание образов, классификация, кластеризация и аппроксимация данных, прогнозирование временных рядов, адаптивное управление и многих других.
Архитектура нейронной сети – совокупность, объединяющая принципы организации и функционирования нейронной сети и отдельных искусственных нейронов, алгоритмы и расчетные соотношения для ее обучения.
Структура нейронной сети - количество слоев, нейронов в каждом слое, а также количество внешних входных и выходных переменных.
Обучение нейронной сети представляет собой процедуру точного или итерационного расчета всех ее весовых коэффициентов, соединяющих внешние входы с нейронами и нейроны между собой.
Под **эпохой обучения** понимается цикл однократного предъявления (как правило, в случайном порядке) всех примеров обучающей выборки для коррекции весовых коэффициентов при одинаковых настройках самой сети и алгоритма ее обучения.

Архитектуры моделей

1. **Однослойный перцептрон:** Простейший тип ИНС, состоящий из одного выходного слоя нейронов. Математически он реализует линейную комбинацию входных сигналов с весами: $s = w_0 + \sum w_i x_i$. Такая структура способна описывать только линейные зависимости.
2. **Многослойный перцептрон (MLP):** Содержит один или несколько скрытых слоев. Каждый нейрон скрытого слоя использует нелинейную **функцию активации**. В работе использована функция **ReLU** ($f(s) = \max(0, s)$), которая позволяет сети «выучивать» сложные нелинейные закономерности.

Алгоритм обучения

Для настройки параметров используется метод обратного распространения ошибки. В качестве оптимизатора применен **Adam** — адаптивный алгоритм, который эффективнее стандартного градиентного спуска (SGD) в задачах со сложным рельефом функции потерь.

Метрики качества

- **MSE (Mean Squared Error):** квадрат ошибки.
- **MAE (Mean Absolute Error):** среднее абсолютное отклонение, показывающее среднюю ошибку в единицах целевой переменной (в долларах).
- **Коэффициент детерминации R^2:** доля дисперсии зависимой переменной, объясняемая моделью. Значение 1.0 — идеальный прогноз, 0.0 — уровень среднего значения.

1.3. Практическая часть

1.3.1. Описание данных

Первым этапом работы было исследование структуры набора данных «Diamonds».

Первые строки датасета:

```
   carat      cut color clarity  depth  table  price     x     y     z
0   0.23    Ideal     E     SI2   61.5   55.0    326  3.95  3.98  2.43
```

```
1   0.21  Premium     E     SI1   59.8   61.0    326  3.89  3.84  2.31
2   0.23     Good     E     VS1   56.9   65.0    327  4.05  4.07  2.31
3   0.29  Premium     I     VS2   62.4   58.0    334  4.20  4.23  2.63
4   0.31     Good     J     SI2   63.3   58.0    335  4.34  4.35  2.75
```

Общая информация о типах данных:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 53940 entries, 0 to 53939
Data columns (total 10 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   carat    53940 non-null  float64
 1   cut      53940 non-null  object
 2   color    53940 non-null  object
 3   clarity  53940 non-null  object
 4   depth    53940 non-null  float64
 5   table    53940 non-null  float64
 6   price    53940 non-null  int64
 7   x        53940 non-null  float64
 8   y        53940 non-null  float64
 9   z        53940 non-null  float64
dtypes: float64(6), int64(1), object(3)
memory usage: 4.1+ MB
```

1.3.2. Предварительный анализ данных (EDA)

Для оценки качества признаков и их распределения были построены следующие графики:

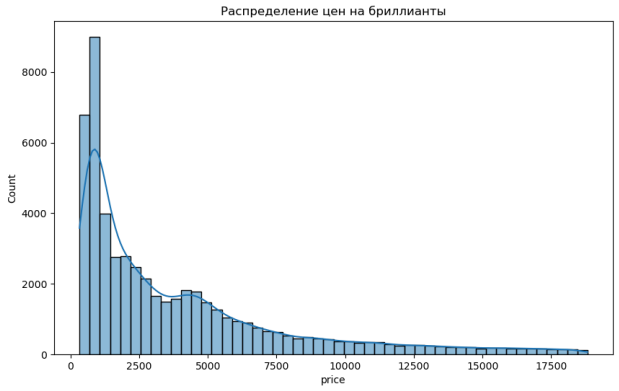

Рис. 1: Распределение целевой переменной Price

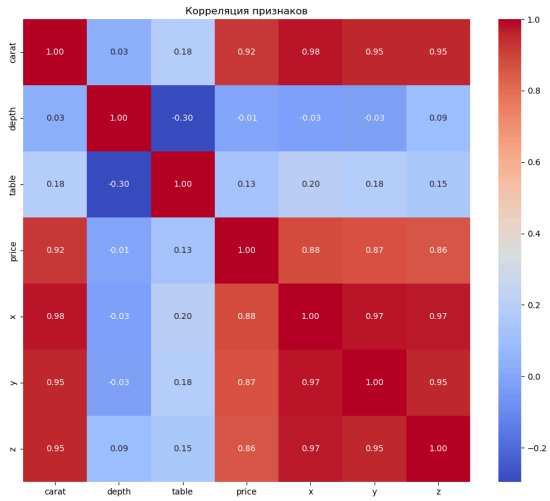

Рис. 2: Матрица корреляций

Анализ: На графике распределения видно, что большинство цен сосредоточено в диапазоне до 5000$.

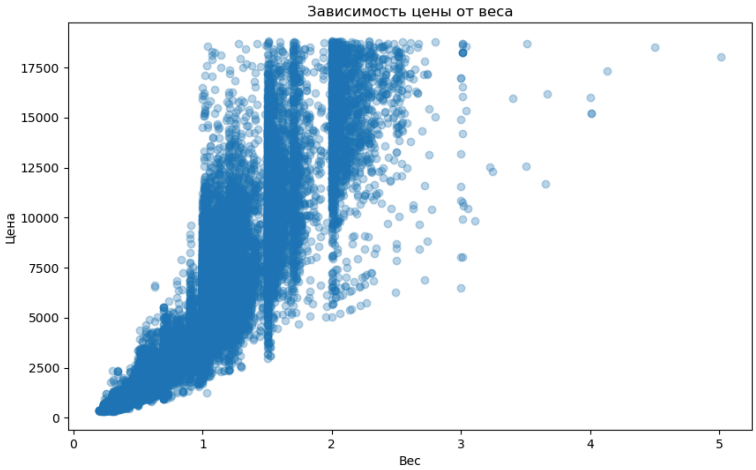

Рис. 3: Взаимосвязь веса в каратах и стоимости

В ходе анализа были визуализированы распределения признаков и построена матрица корреляций.

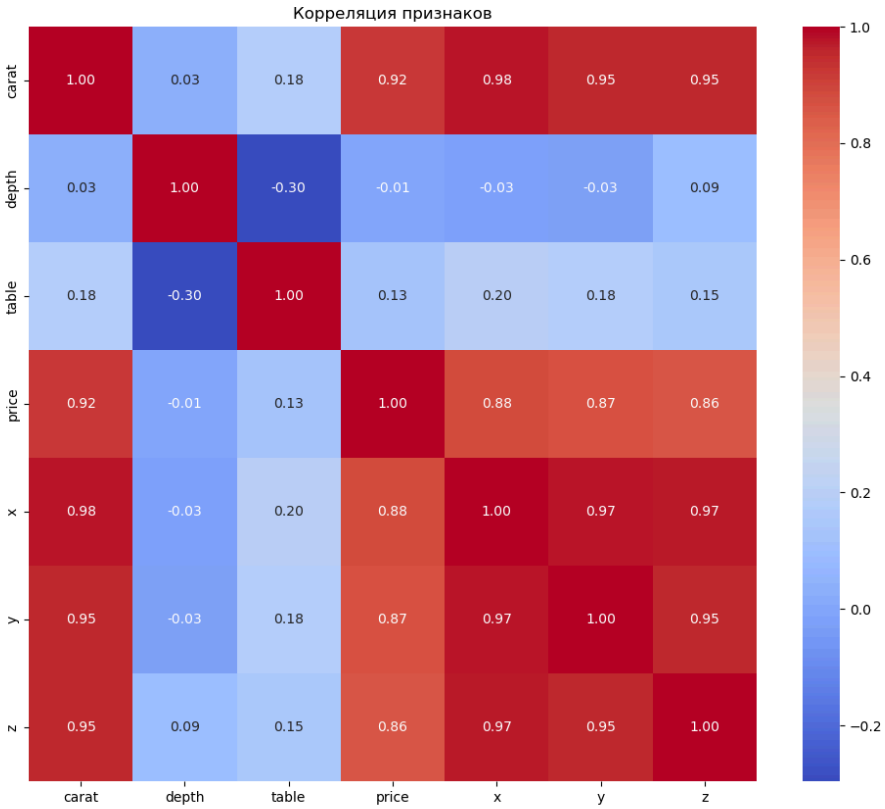

Рис. 4: Матрица корреляций признаков

Выявлено, что на тепловой карте подтверждается сильная корреляция (0.86+) цены с весом (`carat`) и физическими размерами (`x`, `y`, `z`).

1.3.3. Обучение моделей и результаты

Было проведено обучение двух нейронных сетей: однослойного перцептрона и многослойного (MLP) с двумя скрытыми слоями по 64 нейрона. Для обучения использовался оптимизатор Adam. Результаты сравнения моделей на тестовой выборке представлены в таблице ниже.

Модель	MSE	MAE	R^2
Однослойная	3.01e+07	3810.63	−0.9284
Многослойная (MLP)	1.23e+06	617.67	0.9211

Примечание: Отрицательный R^2 у однослойной модели говорит о том, что она предсказывает хуже, чем просто среднее значение по выборке, что подтверждает нелинейность данных. Отрицательное значение R^2 у однослойной модели (-0.9284) математически означает, что модель предсказывает значения хуже, чем если бы мы просто всегда выдавали среднюю цену бриллианта. Это наглядно доказывает, что зависимость цены от характеристик (особенно от каратов) в данном датасете носит выраженный нелинейный характер (например, экспоненциальный), и линейная модель для этой задачи непригодна.

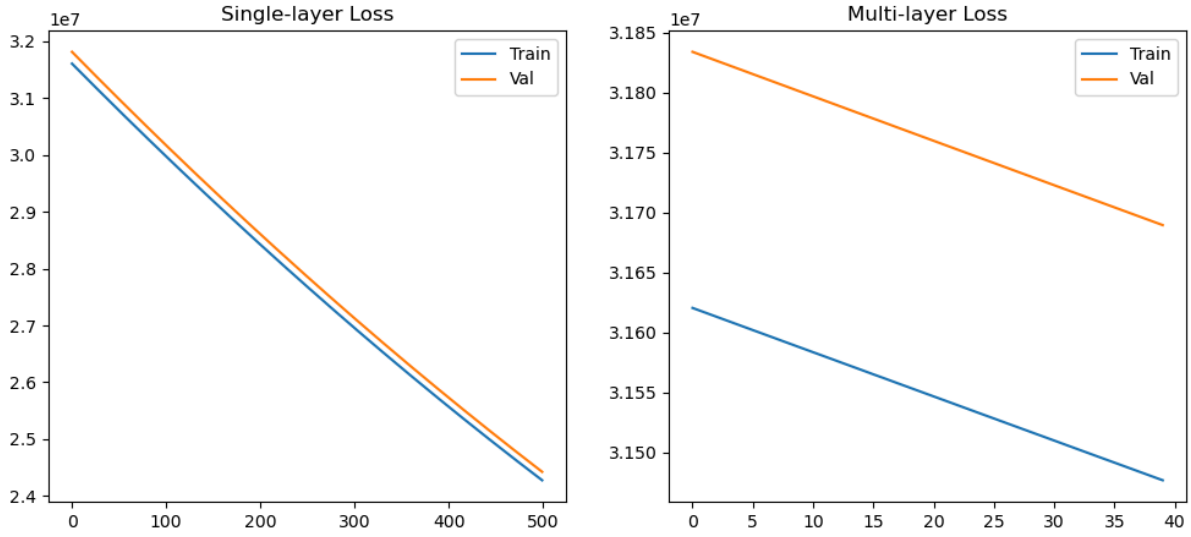

Рис. 5: Сравнение графиков обучения: Однослойная (слева) и Многослойная (справа)

1.4. Выводы по работе

1. В ходе EDA выявлено, что цена бриллианта сильнее всего коррелирует с физическими размерами (`x, y, z`) и весом (`carat`). Это объясняется физической природой объекта: объем определяет массу, а масса — ключевой фактор ценообразования.
2. Нормализация данных является важной: без приведения признаков к единому диапазону $[0, 1]$ градиентные алгоритмы могли работать нестабильно из-за разного масштаба цен и карат.
3. Многослойный перцептрон (MLP) показал MAE в 6 раз ниже, чем однослойная модель. Это подтверждает теорию о том, что введение скрытых слоев и функций активации (ReLU) позволяет нейросети моделировать сложные взаимосвязи между цветом, огранкой и ценой, которые невозможно описать прямой линией.
4. Судя по графикам (Рис. 5), многослойная модель сошлась к 10-й эпохе, при этом кривые обучения и валидации находятся близко друг к другу, что говорит об отсутствии переобучения.